

EcoAI 랩세미나

양자배터리 팀 논문리뷰

○ 2025.07.18 ○

Presenter: 박준성, 이정섭

| 소속: EcoAI Lab

E-mail: js03093351@gmail.com
20211891@edu.hanbat.ac.kr

팀원: [박준성, 박범도], [이정섭, 장현석]

Contents

01 목표 학회 AAAI 일정 / 논문 방향 소개

02 Paper Review 1 (발표: 박준성)


03 Paper Review 2 (발표: 이정섭)

04 Github 7월 활동내역

01

EcoAI 랩세미나 - 양자배터리 팀 논문리뷰

**목표 학회 AAAI 일정 /
논문 진행상황 공유**



Main Conference Timetable for Authors

Note: all deadlines are "anywhere on earth" (UTC-12)

June 16, 2025

Open Review submission site opens for author registration

June 25, 2025

Open Review submission site opens for paper submission

July 25, 2025

Abstracts due at 11:59 PM UTC-12

August 1, 2025

Full papers due at 11:59 PM UTC-12

August 4, 2025

Supplementary material and code due by 11:59 PM UTC-12

September 8, 2025

Notification of Phase 1 rejections

October 2-8, 2025

Author feedback window

November 3, 2025

Notification of final acceptance or rejection (Main Technical Track)

November 13, 2025

Submission of camera-ready files (Main Technical Track)

January 20-27, 2026


AAAI-26 Conference

AAAI-26 Main Conference Timetable

모든 마감 시간은 UTC-12 (한국시간 오후 9:00까지)


- 2025년 6월 18일: 저자 등록을 위한 Open Review 제출 사이트 오픈
- 2025년 6월 25일: 논문 제출을 위한 Open Review 제출 사이트 오픈
- **2025년 7월 25일: 초록(Abstract) 제출 마감**
- **2025년 8월 1일: 전체 논문(Full papers) 제출 마감**
- 2025년 8월 4일: 보충 자료 및 코드 제출 마감
- 2025년 9월 8일: 1단계 심사 탈락(Phase 1 rejections) 결과 통보
- **2025년 10월 2일-8일: 저자 피드백 기간**
- **2025년 11월 3일: 최종 채택 또는 거절 결과 통보 (메인 기술 트랙)**
- 2025년 11월 13일: 최종본(Camera-ready files) 제출 마감 (메인 기술 트랙)
- **2026년 1월 20일-27일: AAI-26 학회 개최**

- (가제)
- 국문 : 커리큘럼 강화학습을 이용한 잡음 환경 양자배터리의 초흡수 충전 최적화
 - 영문 : **Optimizing Dynamic Charging Protocols for Quantum Batteries using a Curriculum-Trained GRU-PPO Agent**



Curriculum Reinforcement Learning

시간적 상관관계 학습




GRU-PPO Agent 구조

02

EcoAI 랩세미나 - 양자배터리 팀 논문리뷰

Paper Review 1 (발표: 박준성)

IBM Quantum Platforms: A Quantum Battery Perspective



Paper Review 1-Contents

2-1 Introduction

2-2 Background

2-3 Methodology

2-4 Experiment and Result


- 양자 배터리(Quantum Batteries, QB)란?

- 개념: 양자 중첩(superposition), 얽힘(entanglement)과 같은 비고전적 양자 현상을 활용하여 기존 배터리의 성능을 뛰어넘도록 설계된 차세대 에너지 저장 장치

- 핵심 성능 지표

- 저장 에너지 (Stored Energy)
- 충전 시간 (Charging Time)
- 평균 충전 전력 (Average Charging Power)
- 추출 가능 일 (Extractable Work)

양자 배터리는 빠르게 성장하는 양자 기술 분야에서 중요한 연구 주제로, 미래에 더 복잡한 양자 장치와 센서에 필요한 에너지를 빠르고 제어된 방식으로 공급할 수 있는 가능성을 제시



양자배터리의 개념적 모델: 에너지원, 충전기, 배터리간의 양자 결합

- 연구 배경

- IBM Quantum과 같은 NISQ(Noisy Intermediate-Scale Quantum) 시대의 양자 컴퓨팅 플랫폼이 발전하면서, 이를 새로운 물리 현상 탐구에 활용하려는 시도가 증가함


- IBM Quantum 칩(:Armonk)를 양자 배터리로 활용

- 양자의 물리적 특성을 반영하는 Quantum 칩 자체를 양자 배터리 환경으로 사용할 수 있지 않을까?

➤ 양자 배터리 관점에서 특성 분석 및 Qiskit Pulse를 이용해 최적의 충전 방법 탐색

- Qiskit Pulse

- Pulse 레벨 제어 기능을 이용해
배터리를 충전하는 클래식 드라이브(펄스)의 다양한 프로파일이 **충전 시간과 저장 에너지**에 미치는 영향을 분석하고 최적의 균형점을 찾는 것을 목표로 함



IBM 양자 프로세서

● 양자 배터리 시스템 모델링

- 시스템: 단일 큐비트 배터리를, 외부 클래식 펄스(충전기)로 구동하는 모델
- 유효한 2-준위 시스템으로 간주할 수 있는 초전도 큐비트(양자 배터리)를 시간에 따라 변하는 외부 클래식 펄스(충전기)로 간주
- 바닥상태 $|0\rangle$ 는 방전, 들뜬상태 $|1\rangle$ 는 충전된 상태를 나타냄

● 시스템 해밀토니안

$$H = H_{QB} + H_C$$

$$H = \frac{\Delta}{2}(1 - \sigma_z) + g f(t) \cos(\omega t) \sigma_x$$

- Δ : 에너지 준위 간격
- $f(t)$: 무차원 펄스 형상 함수 (envelope)
- g : 결합 상수, ω : 드라이브 주파수

● 저장 에너지 계산 모델

- 큐비트의 에너지 간격과 드라이브 주파수가 일치하는 공명 조건에서 가장 효율적인 충전

$$\theta(t_m) = g \int_0^{t_m} f(\tau) d\tau$$

펄스의 누적 면적 θ : 측정 시간 t_m 까지 가해진 펄스의 총량

$$E(a, \phi, \theta) = \Delta \left[a \sin^2 \left(\frac{\theta}{2} \right) + 2\sqrt{a(1-a)} \sin \phi \sin \left(\frac{\theta}{2} \right) \cos \left(\frac{\theta}{2} \right) + (1-a) \cos^2 \left(\frac{\theta}{2} \right) \right]$$

저장 에너지 방정식: 측정 시간 t_m 에 저장된 에너지는 큐비트의 초기 상태 (바닥 상태에 있을 확률 a 와 상대적 위상 ϕ)와 펄스 면적 θ 의 함수로 표현됨

● 실험 플랫폼: IBM Quantum & Qiskit Pulse

- 사용 장비: IBM의 단일 큐비트 프로세서 Armonk
- 핵심 기술: Qiskit의 Pulse 레벨 제어를 통해 충전 펄스의 파형을 정밀하게 프로그래밍

● 측정 원리

- Dispersive Readout(분산 판독) 방식
- 큐비트의 상태 ($|0\rangle, |1\rangle$)에 따라 결합된 공진기(resonator)의 공명 주파수가 미세하게 변하는 현상을 이용
- 이 주파수 변화는 공진기를 통과하는 마이크로파 신호의 진폭과 위상을 변화시킴




Figure 1. 원시 측정 데이터로부터 저장된 에너지를 정량 계산

● 펄스 형태의 영향 및 기술적 제약

- 이론적으로 저장 에너지는 펄스의 구체적인 형태 $f(t)$ 가 아닌, 오직 총 누적 면적(θ)에만 의존해야 함 (Universal Behavior)

● Figure 2

- 검은 실선: 이상적 충전 곡선(오류가 없는 경우) $\rightarrow E(\theta) = \Delta \cdot \sin^2\left(\frac{\theta}{2}\right)$
- 실험 데이터는 초기화 오류로 인해 이상적인 곡선에서 다소 벗어남
- 오른쪽 패널은 매우 짧은 펄스를 사용할 경우임, 이때 IBM 하드웨어의 최소 시간 해상도인 $\delta=0.222\text{ns}$ 에 의해 펄스가 이산화 (discretization) 되어 펄스 파형이 왜곡됨 $\rightarrow$ 충전 효율 급격히 하락. $\rightarrow$ 따라서 충전 펄스의 형태도 고려해야 함




Figure 2. 펄스 형태에 따른 충전 곡선과 기술적 한계

2-4 Experiment and Result

● 충전 성능 분석: 속도/안정성

- 이 그림은 최적화된 가우시안 펄스를 사용하여 얻은 실제 충전 성능 데이터와, 이를 이론 모델로 피팅한 결과

● Figure 3

- 고속 충전: 오른쪽 패널은 측정 시간(t_m)을 135 ns로 설정한 결과. 이처럼 극히 짧은 시간 안에 최대 저장 가능 에너지의 95% 이상을 충전하는데 성공
- 안정성: 이 충전 시간 $t_m = 135\text{ns}$ 은 Armonk 큐비트의 고유한 에너지 완화 시간 및 위상 결맞음(Phase Coherence) 붕괴 시간보다 월등히 짧음.

이는 한번 저장된 에너지가 외부 교란 없이 오랫동안 안정적으로 보존될 수 있음을 의미

- 핵심 결과: Armonk 칩은 별도의 최적화 없이도 매우 효율적이고 안정적인 양자 배터리로 작동할 수 있음을 입증




Figure 3. 실제 충전 성능 및 최적화 결과

● 초기 상태 오류의 영향

- 이 그림은 단순한 바닥 상태가 아닌, 특정 연산자(U, V)를 통해 만든 일반적인 양자 중첩 상태에서 충전을 시작했을 때의 동역학

● Figure 4

- 실제 측정된 충전 과정(데이터 점)은 이상적인 이론적 예측(왼쪽 패널의 경우 에너지가 일정해야 함)과 상당한 차이를 보임
- 이 차이는 초기 상태를 만드는 과정의 불완전성, 즉 초기화 오류 때문에 발생
- 양자컴퓨팅에서는 성능을 저해하는 요인인 이러한 오류(특히 위상 ϕ 의 변동)가 양자 배터리 입장에서는 더 적은 펄스 에너지로 최대 충전에 도달하게 하는 등 오히려 성능을 향상시키는 긍정적인 역할





Figure 4. 다양한 초기 상태에서의 충전 동역학

03

EcoAI 랩세미나 - 양자배터리 팀 논문리뷰

Paper Review 2 (발표: 이정섭)

Proximal Policy Optimization via Enhanced Exploration Efficiency



Contents

3-1 Introduction

3-2 Background

3-3 Methodology


3-4 Experiment

3-1 Proximal Policy Optimization via Enhanced Exploration Efficiency

● Introduction

PPO(Proximal Policy Optimization)

- 에이전트와 환경의 상호작용으로 얻은 샘플을 바탕으로 정책을 최적화 하는 알고리즘
- 기존 TRPO의 장점을 유지하며, 비교적 단순하고 일반적임.
- 에이전트의 탐사 능력에 한계가 존재




3-1 Proximal Policy Optimization via Enhanced Exploration Efficiency

● Introduction

Proposed Method

- IEM(Intrinsic Exploration Module) - PPO
 - 학습 과정에서 불확실성에 대한 내재적 보상을 추가해 탐색 효율을 높임.
- MuJoCo 벤치마크를 통해 PPO, ICM-PPO와 IEM-PPO 비교



3-2 Proximal Policy Optimization via Enhanced Exploration Efficiency

● Background – PPO

Algorithm 1: PPO

- 1: Initial policy parameters θ_0 and value function parameters ϕ_0 .
- 2: **for** $k = 0, 1, 2, \dots$ **do**
- 3: Collect a set of trajectories $\mathcal{D}_k = \{\tau_i\}$ by running policy $\pi_k = \pi(\theta_k)$ by running policy $\pi_k = \pi(\theta_k)$ in the environment.
- 4: Compute reward-to-go R_t .
- 5: Compute advantage estimation $\hat{A}_t$ based on value function V_ϕ .
- 6: Update the policy with Adam by maximizing the clip objective:

$$\theta_{k+1} = \arg \max_{\theta} \frac{1}{|\mathcal{D}_k|T} \sum_{\tau \in \mathcal{D}_k} \sum_{t=1}^T \min(r_t(\theta) \hat{A}_t, \text{clip}(\epsilon, r_t(\theta)) \hat{A}_t).$$

- 7: Approximate value function via gradient descent method by regression on mean-square error:

$$\phi_{k+1} = \arg \min_{\phi} \frac{1}{|\mathcal{D}_k|T} \sum_{\tau \in \mathcal{D}_k} \sum_{t=1}^T (R_t - V_\phi(s_t))^2.$$

8: **end for**

- 정책 파라미터 θ , 가치 함수 파라미터 ϕ 초기화
- 현재 정책 π_k 로 여러 번의 에피소드를 실행 후, 에이전트의 상태, 행동, 보상 등의 정보 (Trajectory) 집합을 수집
- 시점 t 이후의 보상 R_t , 이득 함수 $\hat{A}_t$ 계산
- $\hat{A}_t$ 를 활용한 정책 업데이트
- 새 정책이 과도하게 바뀌지 않도록 Clipping
- MSE를 기준으로 가치 함수 업데이트

3-2 Proximal Policy Optimization via Enhanced Exploration Efficiency

- Background - PPO dilemma
 - PPO의 학습 성능은 노이즈의 분산값(σ)이나 조절 방식에 민감함.
 - (σ 가 작을 때) 탐험 폭이 좁아져 최적의 정책을 찾기 어려움.
 - (σ 가 클 때) 불확실한 행동이 많아져 학습 안정성이 떨어짐.
 - 비효율적인 탐험 과정
 - 학습 초반에는 σ 가 커야 탐험이 활발해지지만, 이후에도 이미 충분히 탐험한 행동들이 반복되어 학습 속도를 저해함.

3-3 Proximal Policy Optimization via Enhanced Exploration Efficiency

● Methodology

Algorithm2: IEM-PPO

- 1: Initial policy parameters θ_0 , value function parameters ϕ_0 and uncertainty estimation function parameters ξ_0 .
- 2: **for** $k = 0, 1, 2, \dots$ **do**
- 3: Collect a set of trajectories $\mathcal{D}_k = \{\tau_i\}$ by running policy $\pi_k = \pi(\theta_k)$ in the environment.
- 4: Compute reward-to-go R_t based on the current uncertainty estimation function $\hat{N}_\xi(s_t, s_{t+1})$ and environmental reward r_t .
- 5: Compute advantage estimation $\hat{A}_t$ based on value function V_ϕ .
- 6: Update the policy with ADAM by maximizing the clip objective:

$$\theta_{k+1} = \arg \max_{\theta} \frac{1}{|\mathcal{D}_k|T} \sum_{\tau \in \mathcal{D}_k} \sum_{t=1}^T \min(r_t(\theta) \hat{A}_t, \text{clip}(\epsilon, r_t(\theta)) \hat{A}_t).$$

- 7: Approximate value function via gradient descent method by regression on mean-square error:

$$\phi_{k+1} = \arg \min_{\phi} \frac{1}{|\mathcal{D}_k|T} \sum_{\tau \in \mathcal{D}_k} \sum_{t=1}^T (R_t - V_\phi(s_t))^2.$$

- 8: Approximate uncertainty estimation function via gradient descent method by regression on mean-square error:


$$\xi_{k+1} = \arg \min_{\xi} \frac{1}{|\mathcal{D}_k|T} \sum_{\tau \in \mathcal{D}_k} \sum_{n=1}^T \sum_{t=1}^{T-n} \left(n - \hat{N}_\xi(s_t, s_{t+n}) \right)^2.$$

- 9: **end for**


- 정책 파라미터 θ , 가치 함수 파라미터 ϕ , 불확실성 추정 함수 파라미터 초기화
- k 번째 반복마다 현재 정책 π_k 로 환경과 상호작용하여 궤적 데이터 수집
- 불확실성 기반 내재적 보상과 환경 보상을 결합한 누적 보상 R_t 계산
- 가치함수 V_ϕ 를 기반으로 어드밴티지 $\hat{A}_t$ 계산
- $\hat{A}_t$ 를 활용한 ADAM으로 정책 업데이트시 안전한 학습을 위해 정책 비율을 범위내로 제한하는 Clipping 적용
- MSE를 기준으로 가치 함수와 불확실성 추정함수 각각 업데이트

3-4 Proximal Policy Optimization via Enhanced Exploration Efficiency


- Experiment – Setting




(a) HalfCheetah-v2



(b) Hopper-v2



(c) Walker2d-v2



(d) Swimmer-v2

Action and state dimensions of our tasks in MuJoCo.

Task	Action dimension	State dimension
HalfCheetah-v2	6	17
Hopper-v2	3	11
Walker2d-v2	6	17
Swimmer-v2	2	8

3-4 Proximal Policy Optimization via Enhanced Exploration Efficiency



- Experiment – Setting

Detailed settings of our algorithm on MuJoCo benchmarks.

Settings	Value
Optimizer	Adam
Learning rate of policy network	3×10^{-4}
Learning rate of other networks	1×10^{-3}
Optimization times of each training episode	80
Discount factor(γ)	0.99
GAE lambda(λ)	0.97
Clipping factor(ϵ)	0.2
Random seed	10000
KL divergence constraint	0.015
Real steps of uncertainty estimation network training(n)	{1,2,3}
β in intrinsic curiosity module	0.02
C_1 in intrinsic exploration module	0.2

3-4 Proximal Policy Optimization via Enhanced Exploration Efficiency


- Experiment – Result



		HalfCheetah	Swimmer	Hopper	Walker2d
PPO	Interacts	4000*1000	2000*500	2000*500	4000*1000
	Reward	4824.30	242.33	2059.52	2760.64
	Variance	544.97	4.55	882.98	1202.87
ICM-PPO	Reward	4834.10	324.16	2018.37	2801.26
	Variance	570.57	2.58	827.87	1213.52
IEM-PPO	Reward	5073.83	367.74	2158.52	2971.12
	Variance	359.92	1.89	770.43	1107.87

3-4 Proximal Policy Optimization via Enhanced Exploration Efficiency

- Experiment – Result




	adjust-0.6	adjust-0.5	adjust-0.4	adjust-0.2
PPO	4824.30	4267.53	4242.58	4084.10
IEM-PPO	5073.83	5252.09	5034.14	4296.04

04

EcoAI 랩세미나 - 양자배터리 팀 논문리뷰

Github 7월 활동내역



README



AI 이미지, 동영상 생성

목적: AI 이미지, 비디오 생성 서비스

지원 모델

이미지 생성 모델	특징	VRAM사용량	단일 요청 시 생성 시간
playground	높은 품질	6~8GB	13~15초
SD XL	높은 품질	6~8GB	13~15초
Animate XL	애니메이션 특화	6~8GB	13~15초

비디오 생성 모델	특징	VRAM사용량	단일 요청 시 생성 시간
wan 2.1	보통 품질	14~15GB	300~360초
animatediff	애니메이션 특화	3~5GB	5초

wan2.1 1~5초 영상 지원, animatediff의 경우 1~2초가 최대

다음 환경에서 생성 시간이 나왔습니다.

GPU: 3090ti

CPU: i9-13900K

RAM: 128GB

젠토에서 진행했던 프로젝트 업데이트

추후 포토폴리오에 타임라인 업데이트 할 예정

README.md

✎ ☰

해외 논문 리뷰 & 세미나 정리

본 레포지토리는 주요 AI 분야 논문 리뷰와 세미나 내용을 정리한 문서입니다.

진행 논문 목록

1. [Densely Connected Convolutional Networks](#)

- **저자:** Gao Huang and others
- **학회:** CVPR 2017
- **요약:** DenseNet 구조의 핵심 개념, 성능 개선 요인, 기존 CNN 대비 차별점 분석

2. [USAD: UnSupervised Anomaly Detection for Multivariate Time Series](#)

- **저자:** Julien Audibert and others
- **학회:** KDD 2020
- **요약:** AutoEncoder 기반의 이중 네트워크 구조를 활용한 비지도 시계열 이상치 탐지 모델 설명 및 실험 분석

3. [LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection](#)

- **저자:** Pankaj Malhotra and others
- **학회:** ICML 2016
- **요약:** LSTM 기반 시계열 인코더-디코더 구조를 이용한 멀티센서 이상치 탐지 프레임워크 분석

4. [Smart Metering System Capable of Anomaly Detection by Bi-directional LSTM Autoencoder](#)

- **저자:** Sangkeum Lee and others
- **학회:** 2022 IEEE ICCE
- **요약:** 스마트 미터링 데이터를 기반으로 Bi-directional LSTM Autoencoder를 활용하여 전력-수도-난방-온수의 이상 소비 패턴을 재구성 오차 기반 탐지, 기존 단방향 LSTM보다 향상된 이상 탐지 성능 입증.

NVIDIA 연구원 세미나

- **제목:** Building High-Performing, Efficient-size Vision Language Models
- **발표자:** NVIDIA 이병관 연구원 [이병관 연구원](#)
- **요약:** 텍스트 생성 기반의 비전-언어 모델(VLM)에서 효율적인 크기와 높은 성능을 달성하기 위한 모델 병합, 네트워크 수정, 지식 증류(distillation) 기법 소개 및 여러 환경에 적합한 경량화 전략 제시

지난달 피드백 반영

- 해외 논문 바로가기 링크 추가
- 연구원님 정보 추가

Good to see you 🤗

👁 About Me

👋 i'm Hyeonseok Jang.

🔥 I aim to become an information security professional.

🎓 Bachelor of computer engineering, Hanbat National University(HBNU)

- A Comparative Study of Customized Algorithms for Anomaly Detection in Industry-Specific Power Data
논문 업데이트
- (진행중) 777사령부 암호분석 경진대회, 블록체인/양자배터리 과제 - 로컬에서 작업 및 정리 후 Github에 push예정

Activities

기간	활동명	내용	기관(장소)
2025	A Comparative Study of Customized Algorithms for Anomaly Detection in Industry-Specific Power Data(SCIE)	DBA K-Means 모델 부분(공저자)	MDPI journal energies
~ 2025.07.14	산업통상자원부 공공데이터 활용 아이디어 공모전	중소 발전사업자를 위한 태양광 발전량-정산금 예측 통합 플랫폼	산업통상자원부
2025.06.30 ~ 07.11	기업 인턴십	자율주행 로봇 시뮬레이션 및 경로 최적화 (Gazebo)	(주) 아군
2025.06.24 ~ 06.27	대한전자공학회 하계 종합학술대회	고속 푸리에 변환(FFT) 기반 주기 추출 및 원도우 구성을 활용한 GELU CNN-GRU AE 모델의 산업 전력 시계열 이상치 탐지	롯데호텔 제주(중문)
2025.05.20 ~ 06.30	ABC 프로젝트 멘토링	산업 전력 소비량 이상치 검출 및 최적화	유클리드 소프트
2025.06.13	데이터분석 준전문가(ADsP) 취득	데이터 분석 기획 및 수행 실무자 자격	-
2025.05.01 ~	Eco AI Lab 랩장	커뮤니케이션 지원 및 일정 조율 등	국립한밭대학교 EcoAI Lab
2025.04.07 ~	산학협력 프로젝트	자율주행 주차로봇 운영 소프트웨어 성능 테스트 및 최적화	국립한밭대학교 SW중심대학사업단
2025.03.24 ~	소중한 JUMP-UP Labs	AI(인공지능)를 활용한 산업체 전력 사용량 이상치 탐지	국립한밭대학교 SW중심대학사업단
2025.03.04 ~ 06.13	데이터사이언스(이상금 교수님) 실습조교 25-1 학기	실습자료 제작 및 질의응답 관리	국립한밭대학교 컴퓨터공학과
2025.02.05 ~ 02.07	한국통신학회 동계종합학술발표회	DBA K-Means 군집화 알고리즘 기반 화공산업 전력 사용량 이상치 탐지	강원도 용평리조트
2025.01.16 ~ 01.21	IRO 2024/25 세계대회	대회 진행요원	부산 벡스코

활동내역 추가

- 그린버튼 SCIE 항목 추가

+ 지난 세미나때 추가 요청 받은 3가지 반영!

- EcoAI 랩장
- 데이터사이언스 실습조교
- 기업 인턴십

감사합니다

○ 2025.07.18 ○

Presenter: 박준성, 이정섭

| 소속: EcoAI Lab

| **E-mail:**

js03093351@gmail.com
20211891@edu.hanbat.ac.kr

팀원: [박준성, 박범도], [이정섭, 장현석]