

EcoAI 랩 세미나

양자배터리 팀 논문리뷰

○ 2025.08.01 ○

Presenter: 박범도, 이정섭

| 소속: EcoAI Lab

E-mail: pbeomdo@gmail.com
20211891@edu.hanbat.ac.kr

팀원: [박범도, 박준성], [이정섭, 장현석]

EcoAI 랩세미나 - 양자배터리 팀 논문리뷰

Contents

01

Paper Review 1 (발표: 박범도)

02


Paper Review 2 (발표: 이정섭)

01

EcoAI 랩세미나 - 양자배터리 팀 논문리뷰

Paper Review 1 (발표: 박범도)

Quantum Curriculum Learning



Paper Review 1-Contents

1-1 Introduction

1-2 Background

1-3 Methodology

1-4 Experiment and Result


Quantum Curriculum Learning

Quoc Hoan Tran,^{*} Yasuhiro Endo, and Hirotaka Oshima

Quantum Laboratory, Fujitsu Research, Fujitsu Limited, Kawasaki, Kanagawa 211-8588, Japan

(Dated: July 15, 2025)

Quantum machine learning (QML) requires significant quantum resources to address practical real-world problems. When the underlying quantum information exhibits hierarchical structures in the data, limitations persist in training complexity and generalization. Research should prioritize both the efficient design of quantum architectures and the development of learning strategies to optimize resource usage. We propose a framework called quantum curriculum learning (Q-CurL) for quantum data, where the curriculum introduces simpler tasks or data to the learning model before progressing to more challenging ones. Q-CurL exhibits robustness to noise and data limitations, which is particularly relevant for current and near-term noisy intermediate-scale quantum devices. We achieve this through a curriculum design based on quantum data density ratios and a dynamic learning schedule that prioritizes the most informative quantum data. Empirical evidence shows that Q-CurL significantly enhances training convergence and generalization for unitary learning and improves the robustness of quantum phase recognition tasks. Q-CurL is effective with physical learning applications in physics and quantum chemistry.



블로흐구면

● Abstract


- 단순한 작업부터 점진적으로 복잡한 작업을 학습하도록 Quantum curriculum learning(Q-CurL) 구성
- 미지의 유니터리(V) (= 알려지지 않은 양자 연산)는 블로흐 구의 임의의 점을 특정 각도만큼 회전시키는 연산 (양자 회로가 알려지지 않음)
- 초기 위치가 입력될 때, 연산 이후 결과의 위치를 따르도록 양자 회로를 생성하는 학습 진행. (=유니터리 V를 모방하는 회로 U 생성을 학습)
- 결론적으로 양자 위상 인식 작업에서의 Q-CurL 효과 입증.

● Quantum Machine Learning(QML)란?

- 개념: 양자 컴퓨터의 원리(양자역학)를 활용해 머신러닝 작업을 수행하는 분야.
양자 비트(큐비트)의 중첩 및 얽힘 같은 양자역학적 특성을 이용해
기존 컴퓨터로는 어려운 문제를 더 효율적으로 해결하려는 목표를 가짐.

● QML의 이론적 가능성

- 양자얽힘 및 중첩을 통한 고속 탐색
- 고차원 힐베르트 공간에서의 정보 표현
- 고전 머신러닝으로는 어려운 함수 표현력 확보



QML은 무엇인가?

기존 QML 연구는 주로 양자 모델이 고전 모델보다 빠른 계산 속도와 표현력 (fidelity)을 가지는지에 초점을 맞추,
그러나 본 논문은 QML의 목표가 단순히 속도 우위가 아닌, 더 나은 학습을 유도
할 수 있어야 한다고 제시

- QML의 주요 한계점

- 노이즈 및 디코히어런스 (decoherence)
 - 현재 NISQ (Noisy Intermediate-Scale Quantum) 시대의 양자 하드웨어는 매우 불안정
 - 큐비트의 상태는 시간이 지남에 따라 환경에 의해 쉽게 무너짐
- Barren Plateau(불모의 고원) 문제 ~ 인공지능경망 기울기 소실과 유사.
 - **PQC 최적화 시** gradient가 0에 가까운 평평한 지역(barren region)에 갇혀 학습 불가능
- 양자 데이터셋의 부족
 - 자연 또는 실험에서 얻을 수 있는 의미 있는 양자 데이터의 획득이 매우 제한적

- 핵심 문제 정의

- 복잡한 양자 회로 구조에서 단일 유니터리(task)를 학습하는 것은 매우 어려움
- **초기화 방식과 데이터 분포에 따라 훈련 안정성이 크게 영향**을 받음
 - 학습 난이도 조절을 위한 전략이 필요



중첩 상태의 슈뢰딩거의 고양이

- **Curriculum Learnig**이란?

- 처음에는 간단한 작업이나 데이터를 제시하고, 점진적으로 더 복잡하거나 어려운 작업/데이터로 나아가도록 훈련시키는 방식

“쉬운 것부터 어려운 것으로 학습을 진행하는 전략”


- **QML에 커리큘럼 학습이 필요한 이유**

- QML은 환경이 불안정하고, reward가 희소하며, optimization landscape가 복잡
- 일반 QML : 모든 task를 동시에 학습 → 불안정, 수렴 실패
- 커리큘럼 학습을 통해:
 - 쉬운 양자 task부터 시작 → 점진적 학습 → 최종 목표 task로 수렴 유도
 - 특히, 복잡한 unitary 또는 노이즈 환경에 점진적으로 적용


● FIG.1: Q-CurL 프레임워크의 커리큘럼 구조 시각화

- (a) Task-based Quantum Curriculum Learning
 - 쉬운 Auxiliary Task (T_m)를 먼저 학습
 - 학습된 모델 파라미터를 Main Task (T_M)로 전이
 - task 간 유사도(similarity) 기반 가중 평균 적용
- (b) Data-based Quantum Curriculum Learning
 - Loss 기반 샘플 가중치 부여
 - 학습 초기에는 쉬운 샘플을 우선 학습
 - 학습이 진행될수록 어려운 샘플의 비중 증가

(a) Task-based Quantum Curriculum Learning



(b) Data-based Quantum Curriculum Learning



1-4 Experiment and Result

● 실험 설계

- 실험 모델: QCNN(Quantum Convolutional Neural Network)
- 환경 조건: Ideal (이상적) vs. Noisy (잡음 포함) 환경
- 비교 실험 구성: Task-based Q-CurL: 유사 작업으로 초기화 후 main task 수행 / Data-based Q-CurL: 쉬운 샘플 → 어려운 샘플 순으로 학습.


(a) Task-based 커리큘럼 설계 메커니즘

- ✓ 메인 task와 유사할수록 더 높은 가중치 부여
- ✓ 유사성 기반 커리큘럼 학습 설계


(b) Q-CurL의 학습 성능

- ✓ 기존 랜덤 샘플링 대비 더 빠른 수렴 속도
- ✓ 더 낮은 학습 손실 및 테스트 손실 확보
- ✓ task 수가 많을수록 Q-CurL의 효과 더욱 강조

(a) Distance with main task ($\Delta_{M,m}$) and curriculum weight ($c_{M,m}$)



(b) Performance of Q-CurL game



1-4 Experiment and Result

● 실험 설계

- 비교 대상: Q-CurL 순서 기반 학습 / 랜덤 순서 기반 학습

● 입력 유형


(a) Haar-random Q-qubit 상태

- ✓ 학습 초기, loss가 더 큰(=쉬운) 샘플에 더 높은 weight 부여
 - ✓ 학습이 진행됨에 따라 더 어려운 샘플이 강조되도록 weight 재조정
- 점진적 난이도 수행 = 커리큘럼 학습 핵심 아이디어 반영


(b) Q개의 Haar-random 단일 큐비트 상태를 곱한 상태

- ✓ Q-CurL이 Random 대비 훨씬 빠르게 수렴
- ✓ 특히, test loss가 크게 감소 → 일반화 성능 향상 입증

(a) Haar-random Q-qubit states



(b) Products of Haar-random single qubit states



1-4 Experiment and Result

● 실험 설계


- Data-based Q-CurL의 성능 개선 효과를 두 가지 조건에서 평가한 실험 결과 시각화

(a) 노이즈 수준 변화에 따른 성능 비교 (8큐비트, noise level 변화)

✓ Q-CurL을 적용한 경우, 더 낮은 loss

✓ Q-CurL을 적용한 경우, 더 높은 정확도 유지

→ Q-CurL은 라벨 노이즈가 많은 환경에서도 모델의 일반화 성능을 향상시킴




(b) 큐비트 수 증가에 따른 성능 비교 (noise level 고정)

✓ 동일한 큐비트 수, Q-CurL 적용 시 더 낮은 loss

✓ 큐비트 수가 많아질수록 정확도 향상

→ Q-CurL은 시스템 복잡도가 커질수록 (큐비트 수 증가) 성능 향상 효과



1-4 Experiment and Result

● 실험 설계

- Q-CurL의 적용 방식으로 인한 학습 안정성과 일반화 영향 비교

● 실험 조건


- Q-CurL 미사용 (파란색)
- easy Q-CurL 사용 (초록색)
- hard Q-CurL 사용 (빨간색)

그래프 해석

- 노이즈 환경에서는 쉬운 샘플부터 학습하는 easy Q-CurL이 효과적
- 노이즈가 없는 경우엔 hard Q-CurL이 유리할 수 있음

결론

- Q-CurL은 라벨이 오염된 데이터 환경에서 모델의 일반화 성능을 향상시키는데 효과적이며, 데이터 품질에 따라 학습 커리큘럼을 유연하게 조정할 필요가 있음을 시사




02

EcoAI 랩세미나 - 양자배터리 팀 논문리뷰

Paper Review 2 (발표: 이정섭)

Reinforcement learning optimization of the charging of a Dicke quantum battery



Contents

2-1 Introduction

2-2 Methodology


2-3 Experiment & Result

2-4 Conclusion

2-1 Reinforcement learning optimization of the charging of a Dicke quantum battery

● Introduction

Quantum batteries are energy-storing devices, governed by quantum mechanics, that promise high charging performance thanks to collective effects. Due to its experimental feasibility, the Dicke battery - which comprises N two-level systems coupled to a common photon mode - is one of the most promising designs for quantum batteries. However, the chaotic nature of the model severely hinders the extractable energy (ergotropy). Here, we use reinforcement learning to optimize the charging process of a Dicke battery either by modulating the coupling strength, or the system-cavity detuning. We find that the ergotropy and quantum mechanical energy fluctuations (charging precision) can be greatly improved with respect to standard charging strategies by countering the detrimental effect of quantum chaos. Notably, the collective speedup of the charging time can be preserved even when nearly fully charging the battery.




a. N 개의 TLS가 결합된 Dicke battery

2-2 Reinforcement learning optimization of the charging of a Dicke quantum battery

• Methodology


Proposed Method

- 매개변수 $\lambda_c(t), \lambda_d(t)$ 값으로 Dicke Quantum battery 환경과 상호작용하고, Ergotropy 변화량을 보상으로 받아 강화학습 진행
 - $\lambda_c(t)$: 광자 모드(캐비티)와 TLS(양자)들 간의 결합 강도
 - $\lambda_d(t)$: TLS의 주파수를 조절해 광자와 공명 조건을 제어하는 디튜닝
 - $\varepsilon_1^{(N)}(\tau)$: Ergotropy, 전체 에너지 중 최대 작업량



2-2 Reinforcement learning optimization of the charging of a Dicke quantum battery

- Methodology



2-3 Proximal Policy Optimization via Enhanced Exploration Efficiency

- Experiment & Result

- 전체 해밀토니안(총 에너지 연산자)

$$\hat{H}(t) = \hat{H}_c + (1 + \lambda_d(t))\hat{H}_B + \lambda_c(t)\hat{H}_{int}$$

$$\hat{H}_c = w_0 \hat{a}^\dagger \hat{a} \quad : \text{충전기(광자 캐비티)}$$

$$\hat{H}_B = \sum_{j=1}^N \hat{h}_j^B, \quad \hat{h}_j^B = \frac{w_0}{2} (\hat{\sigma}_j^{(z)} + 1) \quad : \text{배터리 유닛(TLS)들의 에너지}$$

$$\hat{H}_{int} = w_0 \sum_{j=1}^N \hat{\sigma}_j^{(x)} (\hat{a}^\dagger + \hat{a}) \quad : \text{충전기와 배터리 사이의 상호작용}$$

- 두 가지 충전 방식


- 결합 방식(coupling scheme)에서는 결합 강도 $\lambda_c(t)$ 를 시간에 따라 조절하고, 디튜닝 $\lambda_d(t)$ 는 0으로 고정.
- 디튜닝 방식(detuning scheme)에서는 $\lambda_c(t)$ 를 상수로 고정하고, $\lambda_d(t)$ 만 시간에 따라 조절.

- 기존 on-off 방식 settings: $\lambda_c(t) = \frac{\tilde{g}}{w_0}, \lambda_d(t) = 0$

- $\tilde{g}$:는 최대 유효 결합강도
- w_0 : TLS의 여기상태 $|1\rangle$ 와 바닥상태 $|0\rangle$ 사이의 에너지 차이, 0→1이 되는데 필요한 에너지

2-3 Proximal Policy Optimization via Enhanced Exploration Efficiency

● Experiment & Result




$\varepsilon_1^{(N)}(\tau)/\omega_0$: N 개의 TLS중 하나의 유닛에서 추출 가능한 Ergotropy

$E_{tot}^{(N)}(\tau)/E_{tot}^{(N)}(0)$: 에너지 주입량

2-3 Proximal Policy Optimization via Enhanced Exploration Efficiency

● Experiment & Result




$E_1^{(N)}(\tau)/w_0$: n 개의 TLS중 하나의 유닛에서 추출 가능한 ergotropy

$\sigma_{E_1^{(N)}}^2(\tau)/w_0^2$: 단일 배터리 유닛에 저장된 에너지의 분산, 충전 정밀도

2-3 Proximal Policy Optimization via Enhanced Exploration Efficiency

- Experiment & Result



2-4 Proximal Policy Optimization via Enhanced Exploration Efficiency

- Conclusion

시사점

- 실용적인 고성능 양자 배터리 설계에 대한 새로운 방향을 제시.
- 다체계 양자 시스템 제어라는 복잡한 문제에 강화학습이 강력한 도구가 될 수 있음을 입증.

향후 연구

- 실제 실험 장치(초전도 큐비트 등)에서의 검증.
- 에너지 손실, 디코히어런스와 같은 현실적인 요소를 포함한 모델로 확장.
- 다른 종류의 양자 배터리에 본 방법론 적용.

감사합니다

○ 2025.07.18 ○

Presenter: 박범도, 이정섭

| 소속: EcoAI Lab

| **E-mail:**

pbeomdo@gmail.com
20211891@edu.hanbat.ac.kr

팀원: [박범도, 박준성], [이정섭, 장현석]